Amate

Consulta la legislación de Guerrero con el artículo a la vista

Manual de producto y de arquitectura. Qué es Amate, cómo responde, qué tan bien lo hace y cómo está construido, para el despacho que lo va a usar y para el equipo técnico que lo quiera revisar.

Autores

Ing. Edgar David Mariano Ruiz

Williams Reyna Pérez

Versión

Demostración 0.1, octubre de 2026

Probar la demostración

amate-demo.northcentralus.cloudapp.azure.com

Contenido

1. Lo esencial
2. El problema que resuelve
3. Qué hace Amate
4. Cómo llega a una respuesta
5. Qué tan bien funciona
6. Confidencialidad y seguridad
7. Lo que todavía no hace
8. Hoja de ruta
9. Para el equipo técnico
10. Cómo se construyó
11. Respaldo académico y equipo
12. Glosario

Lo esencial

Amate es un asistente de consulta legal para abogados que trabajan en Guerrero. Se le pregunta como a un colega, en lenguaje cotidiano, y responde con el artículo exacto que sustenta la respuesta, copiado literalmente de la ley y con el nombre del ordenamiento. Debajo de cada respuesta muestra los artículos que consultó, para que el abogado los lea completos antes de usar la información.

155	94 %	76 %	100 %
leyes y códigos: todo el portal del Congreso del Estado, la Ley Federal del Trabajo y la LNETB	de las preguntas de prueba encuentran el artículo correcto	de respuestas correctas en una prueba con preguntas que el sistema nunca había visto	de las citas mostradas se verifican letra por letra contra la ley antes de enseñarse

Cuatro cosas lo distinguen de un chat de inteligencia artificial de uso general:

- **No inventa artículos.** Si la cita que redactó no coincide con el texto de la ley, Amate descarta la respuesta y lo dice.
- **Reconoce lo que no sabe.** Si la ley no está en su acervo, responde que no cuenta con esa legislación en lugar de improvisar.
- **Hace las cuentas con fórmulas fijas.** El aguinaldo, las vacaciones, la prima vacacional y el plazo para demandar por despido los calcula el sistema con la fórmula de la ley, no el modelo de lenguaje.
- **La información del despacho no sale a terceros.** El modelo de lenguaje corre en un servidor propio; las consultas no se envían a OpenAI, Google ni a ningún otro proveedor de inteligencia artificial.

El problema que resuelve

La legislación de Guerrero es pública, pero está dispersa. El portal del H. Congreso del Estado publica más de 150 ordenamientos en PDF: la Constitución Política del Estado, siete códigos y decenas de leyes orgánicas y ordinarias, cada una con su propia fecha de última reforma. A eso se suman las leyes federales que aplican en el estado. Encontrar el artículo que responde una consulta concreta exige saber en qué ordenamiento buscar y en qué capítulo, y casi siempre implica abrir varios archivos.

Los asistentes de inteligencia artificial de uso general parecen resolverlo, pero tienen un defecto grave para el trabajo jurídico: cuando no conocen la respuesta, la completan con datos verosímiles. En 2023 un tribunal federal de Nueva York sancionó a dos abogados que presentaron precedentes inventados por ChatGPT (caso *Mata v. Avianca*). En materia legal, un artículo inexistente citado con seguridad es peor que no tener respuesta.

Amate se diseñó alrededor de ese riesgo. Su prioridad es que cada afirmación pueda verificarse contra el texto oficial, y que cuando no pueda sustentarla lo diga.

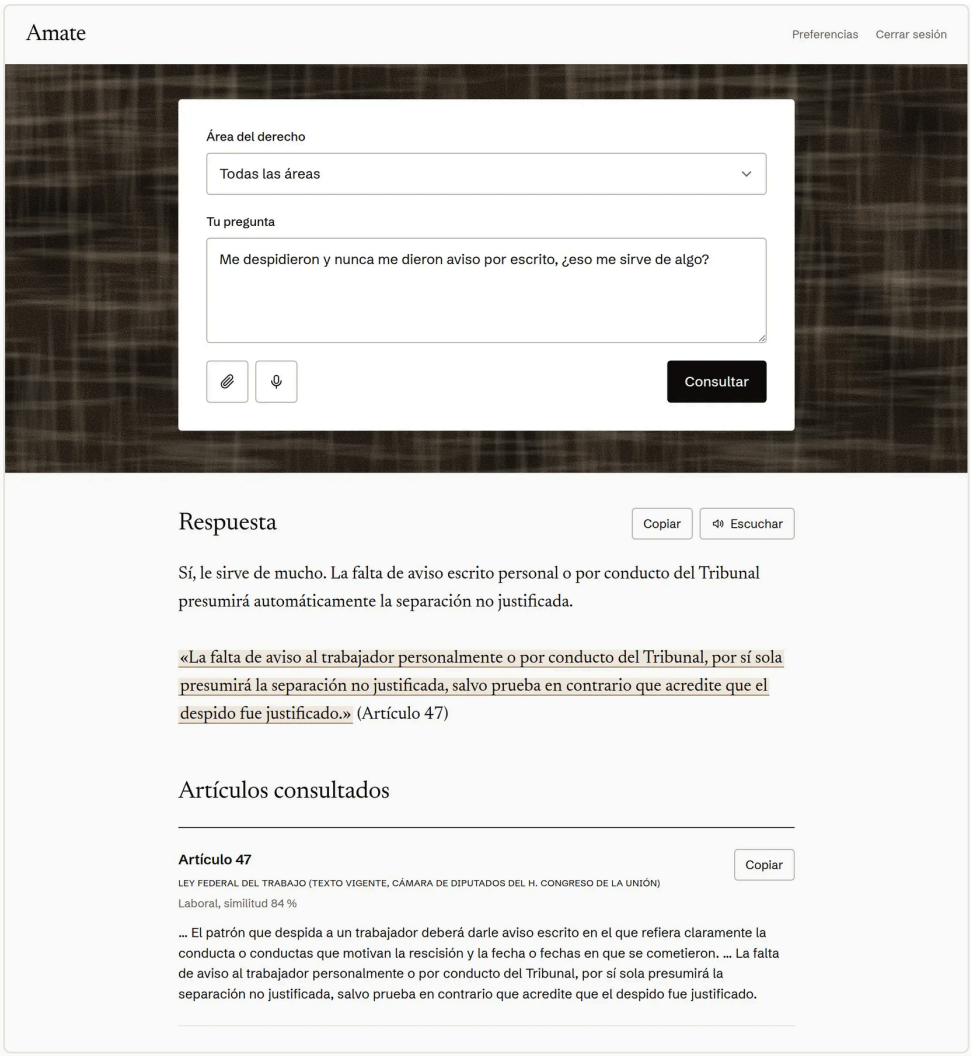
Qué hace Amate

Pregunta del abogado: Me despidieron y nunca me dieron aviso por escrito, ¿eso me sirve de algo?

Sí. La falta de aviso escrito por parte del patrón hace presumir que el despido fue injustificado. Según la Ley Federal del Trabajo: «La falta de aviso al trabajador personalmente o por conducto del Tribunal, por sí sola presumirá la separación no justificada» (Artículo 47).

Artículos consultados: Artículo 47, Ley Federal del Trabajo, y otros seis artículos relacionados, cada uno con su texto completo.

Respuesta real del sistema, resumida. La cita resaltada es la que Amate verificó contra el texto de la ley.



La misma consulta en la interfaz de Amate.

Consulta en lenguaje cotidiano

Entiende preguntas como "me corrieron hace 3 semanas" y las traduce a los términos de la ley (despido, rescisión, prescripción). Se puede filtrar por área del derecho o nombrar una ley para buscar solo en ella.

Cita literal verificada

Cada respuesta trae al menos una cita textual con su artículo. Antes de mostrarla, el sistema la compara con el texto de la ley; si no coincide, la respuesta no se muestra.

Vigencia de las leyes

Detecta leyes abrogadas a partir de los transitorios. "¿Está vigente la Ley 777 del Sistema de Seguridad Pública?" se responde con el transitorio de la Ley 179 que la abrogó.

Cálculos laborales

Aguinaldo proporcional, días de vacaciones por antigüedad, prima vacacional y plazo de dos meses para demandar por despido, con la operación a la vista. Solo se aplican cuando la consulta se rige por la Ley Federal del Trabajo.

Documentos del caso

Se puede adjuntar un PDF, Word o texto para preguntar sobre él. El documento solo se usa en esa sesión, no lo ve nadie más y se borra a las 24 horas.

Voz, móvil y acceso sin cuenta

Permite dictar la pregunta y escuchar la respuesta. Funciona en el celular y, para la demostración, se puede consultar sin registrarse.

Cómo llega a una respuesta

Amate trabaja como un pasante cuidadoso con un revisor detrás. Primero busca los artículos; después redacta usando solo lo que encontró, y al final otra parte del sistema revisa que lo citado diga exactamente eso. La técnica se llama generación aumentada por recuperación (RAG, por sus siglas en inglés).

1. ### Entiende la pregunta

   Reescribe la consulta en términos jurídicos: "me corrieron" se vuelve "despido, rescisión de la relación de trabajo". Sin este paso, el sistema encuentra el artículo correcto en 81 % de los casos; con él, en 94 %.

2. ### Busca de dos maneras a la vez

   Por palabras, como el índice de un código, y por significado, que reconoce que "pensión para mis hijos" y "alimentos" hablan de lo mismo. Revisa 22,769 fragmentos de ley, y si la pregunta nombra un ordenamiento busca solo en él.

3. ### Redacta con lo encontrado

   El modelo de lenguaje recibe los artículos y una instrucción estricta: responder solo con ese texto y copiar literalmente al menos un fragmento.

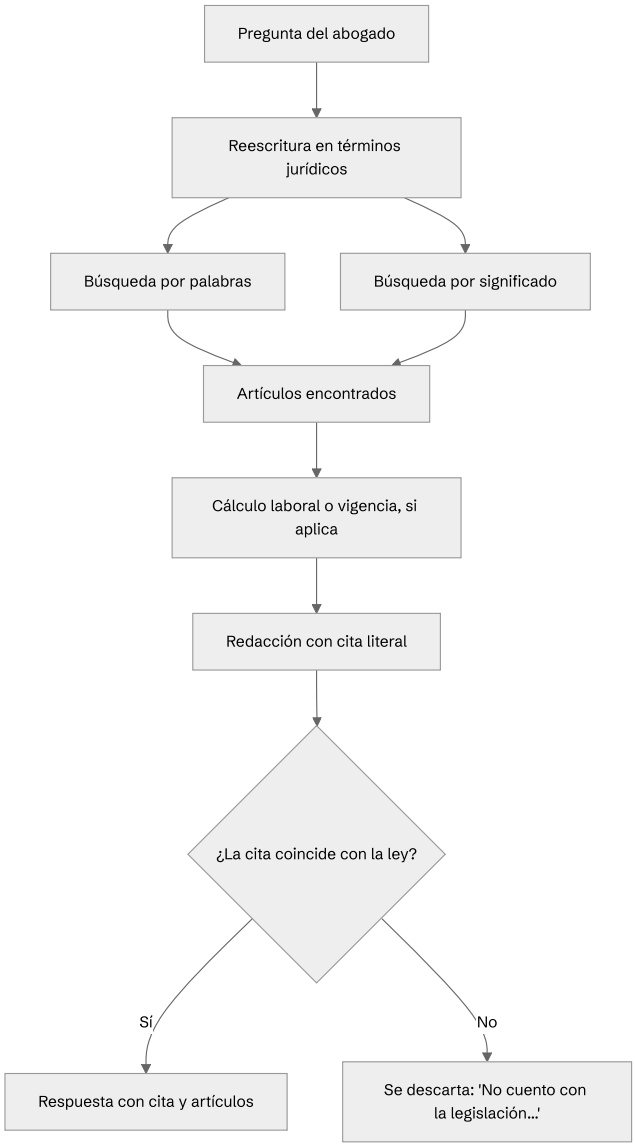
4. ### Verifica cada cita

   El sistema compara la cita con el artículo al que se atribuye. Si no aparece tal cual, descarta la respuesta y contesta "No cuento con la legislación necesaria en mi base de datos para responder a esta consulta".

5

Muestra la evidencia

La respuesta llega con la cita resaltada y, debajo, los artículos consultados completos, con el nombre de la ley y su área.



Qué tan bien funciona

Las cifras de este manual salen de pruebas con respuesta conocida, no de impresiones. Se escribieron preguntas de abogado con la respuesta correcta y el artículo que la sustenta, y cada una se hizo tres veces al sistema. Hay dos juegos: 21 preguntas que se usaron para ajustar el sistema y 17 de validación que nunca se usaron para ajustarlo. La cifra que se reporta es la de validación. Cada respuesta se calificó a mano contra la respuesta esperada.

Indicador (validación, 17 preguntas × 3)	Resultado
La búsqueda encuentra el artículo correcto	94 % (45/48)
Respuestas correctas, calificadas a mano	76 % (39/51)
Pregunta sobre una ley que no está en el acervo (Ley de Amparo): responde que no cuenta con ella	3 de 3
Tiempo por respuesta en servidor con GPU	1–5 s

Las fallas se concentran en preguntas que piden razonar sobre requisitos. Con "tengo 25 años, ¿puedo adoptar?" el modelo cita bien el artículo 555 del Código Civil, que exige más de treinta años, pero a veces concluye mal. En pruebas con un modo de "razonamiento" del modelo esas respuestas incorrectas desaparecieron, aunque cada respuesta tarda más; es parte de la hoja de ruta.

Cómo se eligió el modelo de lenguaje

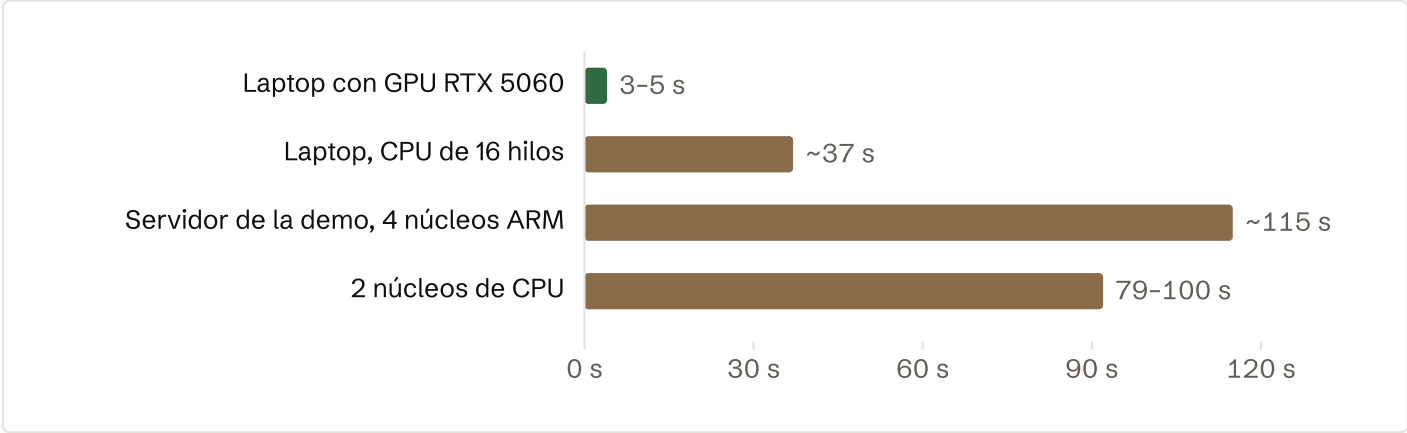
Se compararon cinco modelos abiertos con las mismas 21 preguntas, tres veces cada una. Qwen3.5 de 4 mil millones de parámetros fue claramente el mejor, aun frente a un modelo casi del doble de tamaño.

Modelo (licencia Apache 2.0)	Correctas	Rechazos
Qwen3.5 4B (elegido)	**73 %**	**8**
Qwen2.5 7B (anterior)	52 %	12
Granite 4.0 Tiny	25 %	33
Qwen2.5 3B	10 %	57
Gemma 4 E2B	8 %	54

63 respuestas por modelo (21 preguntas × 3). Después de esta comparación se mejoró la búsqueda, y la validación pasó de 69 % a 76 % de respuestas correctas con el mismo modelo.

Velocidad

El tiempo de respuesta depende del equipo en el que corre el modelo de lenguaje. La calidad es la misma en todos los casos; cambia la espera.



Consulta completa: reescritura, búsqueda, redacción y verificación. Medido en octubre de 2026 con las mismas preguntas.

Confidencialidad y seguridad

Un despacho maneja información de sus clientes, así que Amate se construyó para que esa información no salga de su control.

- **Inteligencia artificial propia.** El modelo de lenguaje, la búsqueda y la base de leyes corren en el mismo servidor. Ninguna consulta se envía a un servicio externo de inteligencia artificial.
- **Software libre.** Todos los componentes son de código abierto. No hay licencias por usuario ni dependencia de un proveedor.
- **Documentos temporales.** Los archivos que se adjuntan quedan aislados por sesión y se borran a las 24 horas.
- **Conexión cifrada y accesos controlados.** HTTPS, contraseñas guardadas con bcrypt, sesiones con vencimiento y límites de uso por conexión. Desde internet solo se expone la página; la base de datos y el modelo no son accesibles desde fuera.
- **Revisión de seguridad documentada.** El proyecto mantiene una lista de verificación de ciberseguridad (contenedores, inyección de instrucciones, validación de entradas, autenticación) y un borrador de aviso de privacidad.

La demostración corre en un servidor de Microsoft Azure en Illinois, EE. UU. Para la operación con información real de clientes, el mismo sistema se puede instalar en un servidor del despacho o en un centro de datos en México.

Lo que todavía no hace

Decir con claridad los límites es parte de la propuesta: una herramienta legal en la que se confía tiene que ser predecible.

- **No sustituye el criterio del abogado.** Es una herramienta de consulta. Cada respuesta debe verificarse contra la fuente antes de usarse en un trámite, y la interfaz lo recuerda.

- **Acervo en construcción.** Todavía no incluye la Constitución federal, la Ley de Amparo, el Código Nacional de Procedimientos Penales, el Código Nacional de Procedimientos Civiles y Familiares ni jurisprudencia.
- **Fecha de corte.** Las leyes son las publicadas en el portal del Congreso a octubre de 2026. Algunos PDF del portal pueden no traer las reformas más recientes, y el acervo debe actualizarse cuando haya reformas.
- **Escritos.** La generación de documentos en Word funciona, pero sus plantillas son de prueba; las plantillas reales deben redactarlas y revisarlas abogados.
- **Velocidad de la demostración.** El servidor de la demostración no tiene GPU, así que cada respuesta tarda alrededor de dos minutos. Con GPU tarda de 1 a 5 segundos.

Hoja de ruta

1. ### Prueba de aceptación con el despacho
   De 20 a 30 preguntas reales del despacho, con su respuesta esperada, que no se hayan usado para ajustar el sistema. Esa será la cifra de aceptación.

2. ### Servidor con GPU
   Respuestas en segundos y la posibilidad de activar el modo de razonamiento, que en pruebas eliminó las respuestas incorrectas.

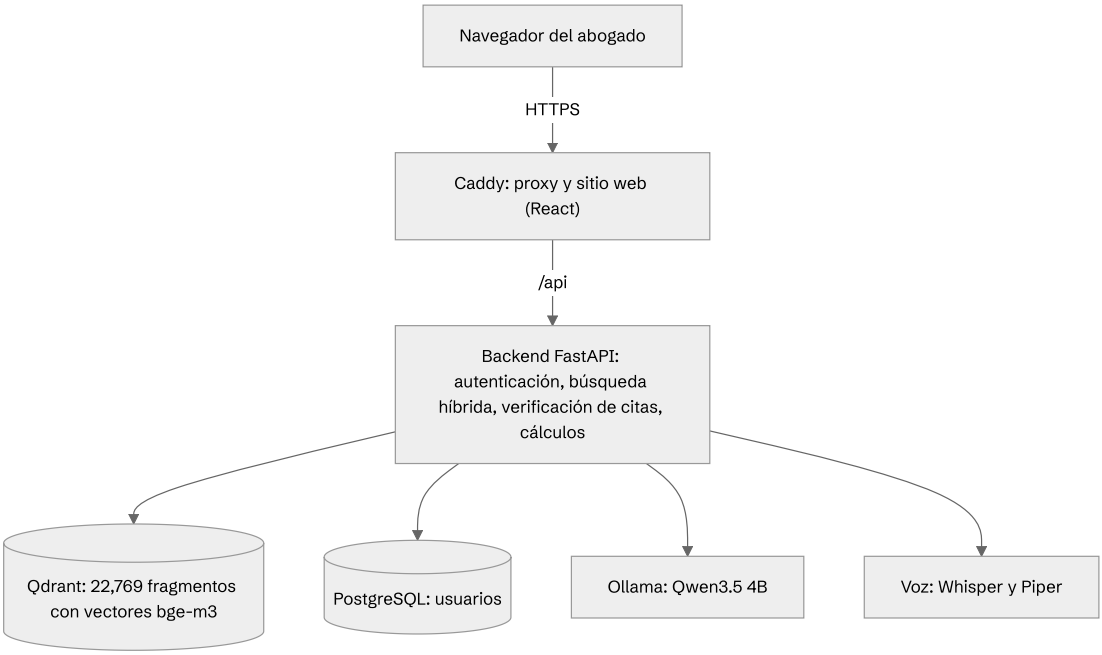
3. ### Ampliar el acervo
   Legislación federal aplicable en Guerrero y, después, jurisprudencia, con un proceso periódico para incorporar reformas.

4. ### Escritos reales
   Plantillas de demandas y promociones redactadas y revisadas por abogados, llenadas a partir de la consulta.

Parte 2. Para el equipo técnico

Arquitectura

Amate es una aplicación web con arquitectura RAG híbrida, autohospedada y empaquetada con Docker Compose. Todo el código, la documentación y las pruebas viven en un mismo repositorio y siguen el principio de documentación como código.



Componente	Tecnología	Por qué
Interfaz	React 18, Vite, TypeScript	Ligera; sin librerías de UI; responsive, modo oscuro y tamaño de letra ajustable.
Proxy	Caddy 2	HTTPS automático con Let's Encrypt; IP real del cliente para los límites de uso.
API	FastAPI (Python 3.11)	JWT, bcrypt y límites por IP con slowapi; 88 pruebas automatizadas.
Modelo de lenguaje	Qwen3.5 4B en Ollama, sin modo de pensamiento	El mejor de la comparación propia; licencia Apache 2.0; cabe en 8 GB de GPU o en CPU.
Embeddings	BAAI/bge-m3 (1,024 dimensiones)	Ganó la comparación contra multilingual-e5 y un modelo jurídico-administrativo en español (MRR 0.683 contra 0.416–0.553).
Búsqueda	BM25 con stemming en español más vectores en Qdrant	Las palabras exactas encuentran lo que el significado pierde y viceversa.
Datos	Qdrant 1.11, PostgreSQL 16	Base vectorial y usuarios, ambas solo en la red interna.

Decisiones clave

Búsqueda híbrida	Se unen los mejores resultados de BM25 y de vectores, usando la pregunta original y la reescrita. Si la pregunta nombra una ley (por nombre completo, corto o siglas), la búsqueda se limita a ella. Las preguntas "¿qué es X?" buscan la definición en los artículos de definiciones.
Salvaguardas deterministas	La verificación de citas, los cálculos laborales y la vigencia por transitorios se resuelven con código, no con el modelo: los modelos pequeños fallan en aritmética y llegaron a contradecir un transitorio que tenían enfrente.
Contexto de 8,192 tokens	Medido: reducirlo a 4,096 ahorra alrededor de 20 % del tiempo en CPU, pero la proporción de preguntas en que el modelo lee el artículo correcto baja de 94 % a 81 %. Se conserva 8,192.
Reescritura de la consulta	Cuesta una llamada extra al modelo, pero sin ella la búsqueda baja de 94 % a 81 %.
Autohospedado	Sin APIs de terceros por confidencialidad. El mismo docker-compose corre en una laptop con GPU, en un servidor del despacho o en la nube.

Despliegue de la demostración

Máquina virtual Azure `Standard_B4ps_v2` (4 núcleos ARM, 16 GB) con Ubuntu 24.04, en la región North Central US, dentro del crédito educativo. Solo los puertos 80 y 443 están abiertos a internet; el acceso de administración es por SSH con llave y desde una sola IP. Para producción con GPU basta con un archivo de configuración adicional (`docker-compose.gpu.yml`).

Dónde empezar a leer el repositorio

Documento	Contenido
`README.md`	Cómo correr el proyecto en local, con GPU y en la nube.
`docs/arquitectura.md`	Decisiones de infraestructura, cómputo y despliegue.
`docs/refactorizacion_rag.md`	Diagnóstico y mejoras de la búsqueda, con la comparación de embeddings.
`docs/investigacion_llm.md`	Investigación y comparación de modelos de lenguaje; evolución de la precisión.
`docs/investigacion_nube_gpu.md`	Opciones de nube con GPU y mediciones de velocidad.
`docs/security_checklist.md`	Controles de ciberseguridad y su estado.
`docs/despliegue_nube.md`	Cómo se montó y se actualiza la demostración.
`backend/eval/`	Evaluador de punta a punta y los dos juegos de preguntas.

Cómo se construyó

El desarrollo siguió un ciclo de medir, cambiar y volver a medir. Cada decisión importante quedó documentada con su evidencia en el repositorio.

1. **Requerimientos y seguridad (septiembre de 2026)**
   Entrevista con el usuario objetivo, requerimientos, arquitectura, lista de verificación de ciberseguridad y borrador de aviso de privacidad.

2. **Prueba técnica local**
   Primer sistema completo con la Ley Federal del Trabajo (1,264 artículos), autenticación, límites de uso y pruebas automatizadas.

3. **Acervo de Guerrero (10 de octubre)**
   Ingesta de todo el portal del Congreso del Estado: 153 documentos segmentados por artículo, con su fecha de última reforma y sus transitorios.

4. **Diagnóstico y rediseño de la búsqueda**
   Casos reales que fallaban se usaron para rehacer la búsqueda: reescritura de la consulta, búsqueda híbrida, detección de la ley mencionada y filtro por área.

5 **Embeddings y modelo de lenguaje (26 de octubre)**

Comparación de cuatro modelos de embeddings y cinco modelos de lenguaje con preguntas propias. El acervo se re-embebió con bge-m3 en GPU.

6 **Salvaguardas y validación**

Verificación de citas, cálculos y vigencia deterministas. Validación ciega: 94 % de recuperación y 76 % de respuestas correctas.

7 **Producto y velocidad (27 de octubre)**

Identidad visual de Amate, acceso como invitado y modelo en GPU: de 37 a entre 3 y 5 segundos por consulta.

8 **Demostración en la nube (28 de octubre)**

Servidor propio en Azure con HTTPS y la base de leyes ya calculada, sin depender de la laptop de desarrollo.

Respaldo académico y equipo

Amate aplica a la legislación de Guerrero el método desarrollado en la tesis de maestría *Sistema conversacional basado en generación aumentada por recuperación para mejorar la precisión factual y reducir el tiempo de acceso a información normativa y procedimental: caso UAGro* (Maestría en Ingeniería para la Innovación y Desarrollo Tecnológico, Facultad de Ingeniería, Universidad Autónoma de Guerrero). La revisión sistemática de esa investigación, conforme a PRISMA 2020, analizó 24 estudios sobre RAG y no encontró ninguno con documentos en español. Amate atiende justo ese hueco, en el terreno donde el error tiene más costo: la consulta jurídica.

Ing. Edgar David Mariano Ruiz

Arquitectura, desarrollo y evaluación del sistema. Autor de la tesis de maestría en la que se basa el método.

Williams Reyna Pérez

Coautor del proyecto.

Glosario

Acervo	El conjunto de leyes y códigos que Amate consulta. Hoy, 155 ordenamientos divididos en 22,769 fragmentos.
Alucinación	Cuando un modelo de inteligencia artificial afirma algo falso con apariencia de verdad, como un artículo que no existe.
Embeddings	Una representación numérica del significado de un texto. Permite encontrar "alimentos" cuando alguien pregunta por "la pensión de mis hijos".

Fragmento	La unidad que el sistema busca y cita: normalmente un artículo completo; los artículos muy largos se dividen por párrafos.
Modelo de lenguaje (LLM)	El programa que redacta la respuesta. En Amate solo puede usar los artículos que le entrega la búsqueda.
RAG	Generación aumentada por recuperación: primero se recuperan los documentos pertinentes y después se redacta con ellos.
Recuperación	La búsqueda de los artículos pertinentes. Se mide con qué frecuencia el artículo correcto llega a manos del modelo.

Manual de Amate, versión de demostración 0.1, octubre de 2026. Las cifras provienen de las evaluaciones documentadas en el repositorio del proyecto. Amate es una herramienta de apoyo a la consulta y no constituye asesoría legal.